

# 功能实现说明

## test1 MVP 功能实现说明

本文按 Excel 功能点解释当前 test1 已实现了什么、代码在哪里、实现到什么程度。

结论先说明：Excel 是完整产品规划，当前 test1 是本地 MVP，不是全量生产系统。它已经跑通了主链路：

样本输入 -> 字段归一 -> IOC 提取 -> 四智能体证据块 -> 模型甲/乙本地 Qwen 研判 -> 仲裁 -> WEC 三引擎决策 -> 页面展示 -> SQLite 存储

### 1. 项目目录和职责

| 目录/文件                     | 作用                                 |
|---------------------------|------------------------------------|
| run.py                    | 本地 HTTP 服务入口，提供页面和 API。            |
| engine/pipeline.py        | 核心研判流水线，包含预处理、四智能体、模型甲/乙辩论、WEC 决策。 |
| engine/llm_local.py       | 本地 Qwen2.5-0.5B 加载和推理代码。           |
| data/field_mapping.json   | 字段别名到标准字段的映射配置。                    |
| data/schema.json          | MVP 样本字段规范。                        |
| data/sample_conflict.json | 内置冲突样本。                            |
| data/mvp.db               | SQLite 本地研判报告库。                    |
| web/index.html            | 前端页面结构。                            |
| web/app.js                | 前端交互逻辑，调用 API 并展示结果。               |
| web/styles.css            | 页面样式。                              |
| tests/test_pipeline.py    | 最小自动化测试。                           |
| start.ps1                 | 启动脚本，默认启用本地 Qwen。                  |

### 2. 数据接入与预处理

#### 冲突样本自动拉取功能

Excel 目标：从 A/B 引擎调度中心拉取冲突样本。

当前 MVP 状态：部分实现。当前没有真实 A/B 调度中心，因此改成页面或 API 手动提交 JSON 样本。

代码位置：

| 文件                                     | 代码                                             |
|----------------------------------------|------------------------------------------------|
| <code>run.py</code>                    | <code>POST /api/judgements</code> 接收样本 JSON。   |
| <code>web/app.js</code>                | <code>judgeCurrent()</code> 把页面中的样本 JSON 发给后端。 |
| <code>data/sample_conflict.json</code> | 内置冲突样本。                                        |

当前实现逻辑：

|                                                                                 |
|---------------------------------------------------------------------------------|
| 用户点击“载入示例” -> 前端请求 <code>/api/sample</code> -> 显示 JSON                          |
| 用户点击“开始研判” -> 前端 <code>POST /api/judgements</code> -> 后端调用 <code>judge()</code> |

尚未实现：自动轮询 A/B 引擎、API 鉴权、批量拉取、失败重试。

## 异构特征数据流式解析引擎功能

Excel 目标：支持 JSON、Protobuf、XML 等多格式流式解析。

当前 MVP 状态：部分实现。目前只支持 JSON。

代码位置：

| 文件                              | 代码                                         |
|---------------------------------|--------------------------------------------|
| <code>run.py</code>             | <code>read_json()</code> 读取请求体 JSON。       |
| <code>engine/pipeline.py</code> | <code>judge(raw_sample)</code> 接收 dict 样本。 |

尚未实现：Protobuf、XML、Kafka 流、死信队列、异常数据隔离。

## 增量特征字段动态注册功能

Excel 目标：新字段不用改代码，通过配置注册。

当前 MVP 状态：部分实现。

代码位置：

| 文件                                   | 代码                                       |
|--------------------------------------|------------------------------------------|
| <code>data/field_mapping.json</code> | 配置字段别名。                                  |
| <code>engine/pipeline.py</code>      | <code>normalize_sample()</code> 读取映射并归一。 |

实现方式：

|                                                       |
|-------------------------------------------------------|
| 如果输入字段在 <code>field_mapping.json</code> 中存在，就映射成标准字段。 |
| 如果不存在，也不会丢弃，会原样保留，并记录到 <code>unmapped_fields</code> 。 |

尚未实现：字段类型校验、字段版本管理、配置热加载。

## 字段归一化功能

Excel 目标：把不同引擎的异构字段统一成标准 Schema。

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                      | 代码                 |
|-------------------------|--------------------|
| engine/pipeline.py      | normalize_sample() |
| data/field_mapping.json | 字段映射表              |

例子：

```
{
  "controlUrl": "control_url",
  "packageName": "package_name",
  "engineAScore": "engine_a_score"
}
```

## 威胁指标结构化提取与封装功能

Excel 目标：从 60+ 字段中提取 IP、域名、邮箱、Hash 等 IOC。

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                 | 代码                            |
|--------------------|-------------------------------|
| engine/pipeline.py | IOC_PATTERNS 、 extract_iocs() |

当前支持：

```
ip
domain
email
md5
sha256
```

输出位置：

```
report["preprocess"]["iocs"]
```

尚未实现：URL 规范化、域名白名单、IOC 信誉库查询。

## 研判任务优先级调度队列功能

当前 MVP 状态：未实现。

原因：当前是单样本同步研判，没有任务队列。

未来建议文件：

engine/queue.py

可用 SQLite/Redis 实现 pending/running/done/failed 状态和优先级。

## 样本去重与研判结果快速缓存功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                                    |
|--------------------|---------------------------------------|
| engine/pipeline.py | report_id 使用样本内容 hash 生成。             |
| engine/pipeline.py | insert_report() 使用 INSERT OR REPLACE。 |

已做到：同一标准化样本会生成相同 report\_id，报告会覆盖写入。

尚未实现：真正的“命中缓存直接返回”，目前仍会重新跑一遍研判。

## 特征数据持久化存储功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                 | 代码                                       |
|--------------------|------------------------------------------|
| engine/pipeline.py | init_db()、insert_report()、list_reports() |
| data/mvp.db        | SQLite 数据库                               |

存储内容：

report\_id  
sample\_id  
verdict  
final\_score  
risk\_level  
created\_at  
payload\_json

### 3. 专家智能体集群

#### 智能体生命周期编排引擎功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码           |
|--------------------|--------------|
| engine/pipeline.py | run_agents() |

当前是函数式编排：

```
def run_agents(sample, iocs):
    return [
        static_analysis_agent(sample),
        threat_intel_agent(sample, iocs),
        impersonation_agent(sample),
        business_label_agent(sample),
    ]
```

尚未实现：Agent 健康检查、启动/停止、超时、降级、重试。

#### 智能体并行执行与超时熔断功能

当前 MVP 状态：未实现。当前四个智能体是串行函数调用。

未来建议：改成 `asyncio.gather()`，每个智能体设置 `timeout`。

### 4. 四个智能体的代码

#### 静态解析智能体

Excel 功能包括：

```
应用信息解析
加固壳特征指纹识别
第三方 SDK 风险分析
静态可信度综合计算
静态可信结果输出
```

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                            |
|--------------------|-------------------------------|
| engine/pipeline.py | static_analysis_agent(sample) |

当前读取字段：

```
signature_status
permissions
packer
```

当前实现：

```
签名异常 -> 加风险分
签名正常 -> 降低风险
高危权限，如 SMS、overlay、install、accessibility -> 加风险分
存在 packer -> 加风险分
输出 EvidenceBlock
```

未实现：

```
真实 APK 解析
证书指纹解析
SDK 列表解析
DEX/API 调用分析
Androguard/APKTool/JADX/MobSF 接入
```

情报溯源智能体

Excel 功能包括：

```
通联地址提取
多层域名与 IP 信誉级联查询
多维社交信息关联拓线
黑产家族基因序列关联
生成情报证据块
```

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                               |
|--------------------|----------------------------------|
| engine/pipeline.py | extract_iocs()                   |
| engine/pipeline.py | threat_intel_agent(sample, iocs) |

当前读取字段：

control\_url  
download\_url  
control\_mailbox  
control\_phone  
fraud\_family  
iocs

当前实现：

字段命中 c2/fraud/phish/malware/risk 等关键词 -> 加风险分  
提取到 IOC -> 加风险分  
存在 fraud\_family -> 加风险分  
输出情报证据块

未实现：

VirusTotal/MISP/OpenCTI 查询  
IP/域名信誉级联  
邮箱/手机号社交关系拓线  
黑产家族图谱

仿冒研判智能体

Excel 功能包括：

多模态视觉仿冒检测  
应用名与包名语义编辑距离分析  
正版应用特征库动态管理  
仿冒概率与伤害等级综合评估  
正版应用特征库匹配  
仿冒结果输出

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                          |
|--------------------|-----------------------------|
| engine/pipeline.py | impersonation_agent(sample) |

当前读取字段：

fake\_app  
app\_name  
package\_name  
brand\_similarity

当前实现：

fake\_app 为 true -> 加风险分  
app\_name/package\_name 包含 bank/wallet/pay/loan/secure/finance -> 加风险分  
brand\_similarity >= 0.75 -> 加风险分  
输出仿冒证据块

未实现：

icon 相似度  
CLIP/SigLIP/DINOv2  
OCR  
正版应用库  
编辑距离算法

业务打标智能体

Excel 功能包括：

技术原子特征到业务场景翻译  
恶意行为危害动链  
变种判定

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                           |
|--------------------|------------------------------|
| engine/pipeline.py | business_label_agent(sample) |

当前读取字段：

virus\_name  
fraud\_family

当前实现：

命中 fraud/phish/scam/loan -> 输出“涉诈相关”  
命中 trojan/spy/stealer -> 输出“恶意软件家族”  
输出业务影响证据块

未实现：

完整反诈业务标签体系  
危害动链图谱  
变种聚类  
家族版本演化



## 标准化证据块强制格式校验功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                      |
|--------------------|-------------------------|
| engine/pipeline.py | EvidenceBlock dataclass |

当前统一结构：

```
EvidenceBlock(  
    agent="static_analysis",  
    claim="静态特征风险较低。",  
    evidence=[...],  
    confidence=0.38,  
    missing_fields=[],  
    score=0.38,  
)
```

尚未实现：严格 JSON Schema 校验、错误阻断。

## 5. 双模型辩论仲裁模块

### 辩论会场状态管理与控制功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                      |
|--------------------|-------------------------|
| engine/pipeline.py | debate(evidence_blocks) |

当前是单轮流程：

```
证据块 -> 模型甲初判 -> 模型乙初判 -> 固定交叉质疑文本 -> 仲裁器打分
```

尚未实现：多轮状态机、暂停恢复、辩论日志状态管理。

### 长下文辩论记忆压缩与摘要功能

当前 MVP 状态：未实现。

原因：当前样本和证据块很小，没有长上下文。

### 双模型异构独立初判接口功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                  | 代码              |
|---------------------|-----------------|
| engine/llm_local.py | qwen_generate() |
| engine/pipeline.py  | debate()        |

当前模型：

Qwen/Qwen2.5-0.5B-Instruct

注意：现在模型甲和模型乙使用同一个本地小模型，但通过不同 system prompt 实现两个角色视角：

模型甲：保守复核模型  
模型乙：风险优先模型

不是真正两个异构模型。真正异构需要后续接两个不同模型，例如 Qwen + DeepSeek。

## 模型角色与思维链动态注入功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                           |
|--------------------|------------------------------|
| engine/pipeline.py | build_debate_prompt()        |
| engine/pipeline.py | debate() 中两个不同 system prompt |

当前不要求输出思维链，只要求输出结构化 JSON：

```
{
  "verdict": "malicious | suspicious | benign",
  "score": 0.0,
  "arguments": ["理由1", "理由2"]
}
```

## 强制视角反转功能

当前 MVP 状态：部分实现。

实现方式：模型甲和乙的 prompt 角色不同。

尚未实现：让模型主动反驳自己原结论。

## 对方逻辑漏洞定向攻击生成功能

当前 MVP 状态：占位实现。

代码位置：

| 文件                 | 代码                            |
|--------------------|-------------------------------|
| engine/pipeline.py | debate() 中的 cross_examination |

当前是固定模板，不是模型动态生成。

### 辩护性反驳与证据再援引功能

当前 MVP 状态：占位实现。

当前没有真正多轮反驳，只保留了返回结构。

### 多轮攻辩收敛与共识发现功能

当前 MVP 状态：未实现。

### 辩论逻辑回溯与终审摘要功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码                                                       |
|--------------------|----------------------------------------------------------|
| engine/pipeline.py | debate() 返回 model_a、model_b、cross_examination、arbitrator |

页面展示位置：

| 文件         | 代码                     |
|------------|------------------------|
| web/app.js | renderReport() 渲染双模型辩论 |

### 恶意倾向评分计算与校正功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                 | 代码       |
|--------------------|----------|
| engine/pipeline.py | debate() |

当前公式：

Engine C score = (模型甲分数 + 模型乙分数 + 最强证据块分数 \* 0.25) / 2.25

## 6. 三引擎协同决策

### 关键证据强度特征自动提取功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                 | 代码                                                                                             |
|--------------------|------------------------------------------------------------------------------------------------|
| engine/pipeline.py | <pre>strong_agents = [block.agent for block in evidence_blocks if block.score &gt;= 0.7]</pre> |

当前规则：

|                        |
|------------------------|
| 证据块 score >= 0.7 视为强证据 |
|------------------------|

### 基于证据强度的三引擎权重动态分配功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                 | 代码                        |
|--------------------|---------------------------|
| engine/pipeline.py | <pre>wec_decision()</pre> |

当前规则：

|                                                                                                               |
|---------------------------------------------------------------------------------------------------------------|
| 情报溯源强证据 -> Engine C 权重 +0.45，A/B 各 -0.2<br>仿冒强证据 -> Engine C 权重 +0.25<br>A/B 分数冲突 >= 0.35 -> Engine C 权重 +0.2 |
|---------------------------------------------------------------------------------------------------------------|

### 加权证据共识数学实现与调优功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件                 | 代码                        |
|--------------------|---------------------------|
| engine/pipeline.py | <pre>wec_decision()</pre> |

当前公式：

|                                                                                                                            |
|----------------------------------------------------------------------------------------------------------------------------|
| <pre>Final Score = (Score_A * Weight_A + Score_B * Weight_B + Score_C * Weight_C) / (Weight_A + Weight_B + Weight_C)</pre> |
|----------------------------------------------------------------------------------------------------------------------------|

## 结果反馈功能

当前 MVP 状态：部分实现。

已实现：

返回 JSON 报告  
写入 SQLite  
页面展示历史报告

未实现：

回调外部系统  
人工复核反馈  
模型再训练反馈

## 7. 研判结果展示与交互

### 三引擎评分对比雷达图功能

当前 MVP 状态：未实现。

当前只用 JSON 展示 WEC 权重和分数。

### 研判报告多格式导出功能

当前 MVP 状态：未实现。

未来可增加：

JSON 下载  
PDF 导出  
Markdown 导出  
Excel 导出

### 研判任务列表与状态看板功能

当前 MVP 状态：部分实现。

代码位置：

| 文件                 | 代码               |
|--------------------|------------------|
| run.py             | GET /api/reports |
| engine/pipeline.py | list_reports()   |
| web/app.js         | loadHistory()    |

当前只有“历史报告列表”，没有任务状态队列。

## 单样本全景研判详情页功能

当前 MVP 状态：已实现 MVP。

代码位置：

| 文件             | 代码             |
|----------------|----------------|
| web/index.html | 页面区域           |
| web/app.js     | renderReport() |

当前展示：

|             |
|-------------|
| 最终结论        |
| Final Score |
| 风险等级        |
| 专家证据块       |
| 模型甲/乙/仲裁器输出 |
| WEC 权重和分数   |
| 历史报告        |

## 8. 双模型微调与推理功能

### 大模型高并发推理服务集群部署功能

当前 MVP 状态：未实现生产集群。

已实现的是本地单进程小模型推理：

| 文件                  | 代码                            |
|---------------------|-------------------------------|
| engine/llm_local.py | _load_model()、qwen_generate() |

当前模型：

|                            |
|----------------------------|
| Qwen/Qwen2.5-0.5B-Instruct |
| CPU 推理                     |

### 推理请求缓存与结果复用功能

当前 MVP 状态：未实现。

当前每次点击研判都会重新调用模型。

### 数据采集与接入

当前 MVP 状态：未实现真实数据采集。

当前只有：

data/sample\_conflict.json  
页面手动输入 JSON

### 场景适配与智能标注

当前 MVP 状态：未实现。

### 数据合成与策略优化

当前 MVP 状态：未实现。

### 质量评测与持续回流

当前 MVP 状态：未实现。

### 微调框架配置与模型适配

当前 MVP 状态：未实现微调。

已实现：推理适配。

代码位置：

| 文件                  | 代码                        |
|---------------------|---------------------------|
| engine/llm_local.py | 使用 transformers 加载本地 Qwen |

### 微调参数与策略配置

当前 MVP 状态：未实现。

### 大模型微调

当前 MVP 状态：未实现。

### 模型评估与交付

当前 MVP 状态：未实现正式评估。

当前只有最小单元测试：

| 文件                     | 代码        |
|------------------------|-----------|
| tests/test_pipeline.py | 验证示例样本能跑通 |

### 系统角色与规则的可视化管理功能

当前 MVP 状态：未实现可视化管理。

当前角色 prompt 写在代码里：

| 文件                 | 代码                               |
|--------------------|----------------------------------|
| engine/pipeline.py | debate() 、 build_debate_prompt() |

## 提示词模板 A/B 测试与效果评估功能

当前 MVP 状态：未实现。

## 大模型生成质量与幻觉量化管控

当前 MVP 状态：未实现。

当前只做了最基本的 JSON 解析兜底：

| 文件                  | 代码                                          |
|---------------------|---------------------------------------------|
| engine/llm_local.py | parse_model_json() 、 normalize_llm_result() |

如果模型输出格式不规范，会尽量解析；解析失败时使用规则分数兜底。

# 9. 当前完整调用链

一次页面研判的代码路径如下：



```
web/app.js
  judgeCurrent()
    -> POST /api/judgements

run.py
  do_POST()
    -> judge(payload)

engine/pipeline.py
  judge()
    -> normalize_sample()
    -> extract_iocs()
    -> run_agents()
      -> static_analysis_agent()
      -> threat_intel_agent()
      -> impersonation_agent()
      -> business_label_agent()
    -> debate()
      -> qwen_generate() # 模型甲
      -> qwen_generate() # 模型乙
      -> arbiter score
    -> wec_decision()
    -> insert_report()

web/app.js
  renderReport()
    -> 展示结论、证据块、模型甲/乙、WEC 权重
```

## 10. 当前 MVP 与 Excel 全量规划的差距

当前已实现得比较完整的部分：

字段归一化  
IOC 提取  
四智能体证据块结构  
本地 Qwen 模型甲/乙初判  
基础仲裁  
WEC 三引擎加权  
单样本详情展示  
历史报告存储

当前只是占位或简化的部分：

四智能体内部仍是规则判断，不是真实 APK/情报/视觉/业务系统  
双模型是同一个 Qwen 小模型的双角色 prompt，不是真正异构双模型  
交叉质疑是固定模板，不是多轮动态辩论  
SQLite 只是本地 MVP 存储，不是生产数据库

当前未实现的生产能力：

A/B 引擎自动拉取  
任务队列和优先级调度  
并发执行和超时熔断  
APK 静态/动态分析工具链  
威胁情报 API 和知识图谱  
视觉仿冒检测  
雷达图和报告导出  
模型微调、评估、监控、回流  
高并发推理集群

## 11. 下一步建议

---

建议按这个顺序继续做：

1. 增加任务队列和“研判中/完成/失败”状态。
2. 给四个智能体接真实工具或真实数据源。
3. 把模型甲和模型乙拆成两个不同模型，或者同模型不同 LoRA。
4. 增加报告导出和图表。
5. 增加人工复核反馈，用于后续校准 WEC 权重。